BIT BUILD INNOVATE TRANSFORM

BIT BUILD INNOVATE TRANSFORM

MÓDULO 3 · VISUALIZACIÓN Y BUSINESS INTELLIGENCE · CLASE 9

Probabilidad y estadística

Lo que un promedio no te cuenta

Bootcamp de Ciencia de Datos · 2 horas · Medidas, correlación y probabilidad con Pandas, aplicadas a un negocio de domicilios

BIT BUILD INNOVATE TRANSFORM

BIENVENIDA

El mapa del bootcamp: 6 módulos, 33 clases

MÓDULO 1

Fundamentos y Mentalidad de Datos

Completado

MÓDULO 2

Python para Análisis de Datos

Completado

MÓDULO 3

Visualización y Business Intelligence

Estamos aquí

MÓDULO 4

Extracción de Datos

Bases de datos, SQL, APIs

MÓDULO 5

Machine Learning Básico y Aplicado

Clasificación, regresión, clustering

MÓDULO 6

Proyecto Final y Cierre

Deep Learning, NLP, tu proyecto

33 CLASES

Tu recorrido completo

Mayo a septiembre, 2 clases por semana

CÓMO TRABAJAMOS

Teoría + práctica en cada módulo · talleres integradores · proyecto final

Hoy aprendes a leer los datos con números: es la base de toda gráfica y de todo tablero.

POR QUÉ HOY IMPORTA

Un promedio puede engañar

Un número, muchas historias

Lo que la estadística te enseña a preguntar

- La gerencia de Rápido dice que su pedido promedio supera los $55.000.
- Pero la mitad de los pedidos vale $41.000 o menos: un solo pedido corporativo infla la cifra.
- Las tres sucursales tardan en promedio 35 minutos, pero Sur llega tarde cuatro veces más que Norte.
- La estadística te ayuda a ver lo que un solo número esconde.

¿Por qué justo ahora?

Ya sabes limpiar y resumir datos

En el módulo anterior preparaste tablas con Pandas. Hoy aprendes a leerlas con criterio.

Cada decisión se apoya en números

Metas, alertas y prioridades salen de medidas como la mediana o un percentil.

Prepara el terreno para las gráficas

Un histograma o un diagrama de caja muestran estas mismas medidas.

Hoy aprendes a describir un negocio con pocos números, y a desconfiar del promedio.

CLASE 9

Lo que vamos a lograr hoy



01

Resumir con el número correcto

Elegir entre media, mediana y moda según la forma de los datos y sus valores extremos.



02

Medir la variación

Usar desviación estándar, rango intercuartílico y percentiles para comparar y fijar umbrales.



03

Relacionar y estimar

Leer una correlación sin confundirla con una causa y calcular probabilidades condicionales.

Al final de la clase: un diagnóstico del mes de Rápido con tres recomendaciones apoyadas en números.

MÓDULO 3 · ESTADÍSTICA

Entonces, ¿qué es la estadística descriptiva?

Resumir un conjunto de datos con pocos números: cuál es el valor típico, qué tanto varían los datos y cómo se relacionan sus columnas, sin perder de vista lo que cada número esconde.



Centro

Media, mediana y moda: el valor típico de una columna.



Dispersión

Desviación estándar, rango y rango intercuartílico.



Posición

Percentiles y cuartiles: dónde queda un dato frente a los demás.



Relación

Correlación y probabilidad: cómo se mueven dos variables juntas.

Chequeo rápido: si un empleado nuevo gana 50 veces más que los demás, ¿qué le pasa a la media del salario? ¿Y a la mediana?

MÓDULO 3 · ESTADÍSTICA

Tres preguntas, tres tipos de medida



Centro

¿Cuál es el valor típico?

- mean() promedia todos los valores
- median() resiste los extremos
- mode() sirve para categorías

Valor típico: $41.000



Dispersión

¿Qué tanto varían?

- std() mide la variación
- Rango: máximo menos mínimo
- IQR: Q3 menos Q1

Sur varía el doble que Norte



Posición

¿Dónde queda un dato?

- quantile(0.5) es la mediana
- quantile(0.9) fija una meta
- describe() resume todo junto

P90 del tiempo: 46 min

La regla de oro: nunca reportes un promedio sin mirar la mediana y la dispersión.

MÓDULO 3 · ESTADÍSTICA

Lo que muestra describe() en el archivo de domicilios

1.	Tiempo de entrega: media y mediana casi iguales, los datos son simétricos.	**35 min**
2.	Valor del pedido: la media es $55.359 y la mediana solo $41.000.	**$2.000.000**
3.	Desviación del valor: 127.885, mayor que la media. Señal de un valor extremo.	**std > media**
4.	Calificación: el 25 %, el 50 % y el 75 % valen 4. La mayoría califica con 4.	**4 de 5**
5.	Percentil 90 del tiempo: el 90 % de los pedidos llega en 46 minutos o menos.	**P90 = 46**

Antes de concluir nada, compara media y mediana: si se separan, hay valores extremos.

MÓDULO 3 · ESTADÍSTICA

Cómo encontrar valores atípicos, paso a paso

Ordenar

Organizas los tiempos de menor a mayor

sort_values()

→

Cuartiles

Q1 = 29 y Q3 = 41 minutos

quantile()

→

Rango IQR

Q3 menos Q1: la mitad central mide 12 minutos

IQR = 12

→

Límites

Q1 menos 1,5 IQR y Q3 más 1,5 IQR

11 y 59 minutos

→

Revisar

Dos pedidos se salen: 67 y 72 minutos

revisar, no borrar

Para qué sirven los cuartiles: muestran la mitad central de los datos, permiten comparar qué grupo es más predecible y marcan los valores que vale la pena revisar.

MÓDULO 3 · ESTADÍSTICA

Cómo leer una columna numérica, paso a paso

Centro

Comparas media y mediana para detectar extremos

mean() y median()

→

Dispersión

Mides qué tanto se alejan los datos del centro

std() y quantile()

→

Posición

Ubicas umbrales y metas con percentiles

quantile(0.95)

→

Relación

Buscas qué variables se mueven juntas

corr()

→

Decisión

Conviertes los números en una recomendación

una frase, un número

La idea clave: cada medida responde una pregunta distinta; juntas cuentan la historia que un solo promedio esconde.

MÓDULO 3 · ESTADÍSTICA

Entonces, ¿qué dice una correlación?



Mide si dos variables se mueven juntas

La correlación va de -1 a 1. Cerca de 1, cuando una sube la otra también; cerca de -1, cuando una sube la otra baja; cerca de 0, no hay relación lineal.

Que se muevan juntas no significa que una cause la otra.

Un ejemplo aplicado

Distancia y calificación tienen -0,30. ¿La distancia molesta al cliente? No: los pedidos lejanos tardan más (0,52) y el tiempo es lo que baja la calificación (-0,66). La causa real es la demora.

Dato: df.corr(numeric_only=True) calcula todas las correlaciones de una vez. Descarta columnas de identificación como id_pedido.

MÓDULO 3 · ESTADÍSTICA

Entonces, ¿qué es una probabilidad condicional?



La misma pregunta dentro de un grupo

La probabilidad de un evento es la proporción de veces que ocurre. La condicional calcula esa proporción solo dentro de un grupo: P(tarde | lluvia) se lee probabilidad de llegar tarde dado que llueve.

En Pandas: filtras el grupo y sacas mean() de la condición.

Un ejemplo aplicado

En septiembre, 29 de 240 pedidos llegaron tarde: 12,1 %. Con lluvia la cifra sube a 28,1 % (18 de 64) y sin lluvia baja a 6,2 %. La lluvia multiplica por más de cuatro el riesgo de llegar tarde.

Dato: (df['tiempo_min'] > 45).mean() da la proporción de pedidos tarde: cada True cuenta como 1 y cada False como 0.

PARA LA CASA · 30 MIN

Actividad

1	Aplica la regla de los cuartiles a distancia_km. ¿Hay pedidos atípicos por distancia?	10 min
2	Calcula la probabilidad de recibir una calificación de 3 o menos en todos los pedidos.	5 min
3	Calcula esa misma probabilidad solo en los pedidos con lluvia y di si los eventos son independientes.	10 min
4	Escribe una recomendación de una frase para la gerencia, apoyada en uno de tus números.	5 min

Entregable

El cuaderno de clase con:

- Los límites y los atípicos de distancia
- Las dos probabilidades comparadas
- Una recomendación con su número

Son los mismos pasos de la clase: si te pierdes, vuelve al ejemplo resuelto de cada sección.

La actividad está al final del cuaderno de clase, en la sección Actividad para la casa.

CIERRE · 20 MIN

Cierre: ¿qué le recomendamos a la gerencia?



Valor típico del pedido

Reportar la mediana, unos $41.000, y no la media que infla un pedido corporativo.



Sucursal Sur

Su IQR duplica el de Norte y llega tarde el 21,2 % de las veces, frente al 12,1 % general.



Días de lluvia

El riesgo de llegar tarde pasa de 6,2 % a 28,1 %: conviene reforzar repartidores.

Pregunta de cierre: vuelve a tu respuesta sobre el salario promedio. ¿La cambiarías después de hoy?

RECAPITULEMOS

Las 4 ideas que se llevan hoy

01 **El promedio no siempre es el valor típico**

Con valores extremos, la mediana representa mejor a la mayoría.

02 **El centro no basta sin la dispersión**

Dos sucursales con el mismo promedio pueden ser muy distintas en confiabilidad.

03 **Correlación no es causalidad**

Antes de culpar a una variable, busca la que se mueve con ambas.

04 **La probabilidad cambia según el grupo**

Filtrar por una condición revela riesgos que el total esconde.

Mini-reto de salida (1 frase): explícale a alguien por qué la mediana del salario dice más que el promedio.